

Projeto Aplicado III - Recomendação de Livros

CESAR VALENTIM SILVA - 10416087
JOAO PEDRO SANTOS OLIVEIRA - 10423752
WILLIANS CARVALHO DA SILVA – 10416087

Sumário (Parcial)

1. Introdução
 - 1.1 Contextualização
 - 1.2 Motivação
 - 1.3 Justificativa
2. Referencial Teórico
3. Metodologia
4. Resultados
5. Conclusão e trabalhos futuros

1 INTRODUÇÃO

1.1 Contextualização do trabalho

Os sistemas de recomendação desempenham um papel fundamental na personalização da experiência do usuário em diversas plataformas digitais. No setor literário, plataformas como Amazon, Google Books e Goodreads utilizam algoritmos avançados para sugerir livros aos leitores com base em preferências e interações passadas. A crescente quantidade de títulos disponíveis torna essencial o uso de técnicas de inteligência artificial para otimizar o processo de recomendação e facilitar a descoberta de novos conteúdos.

1.1 Motivação

1.2 A baixa taxa de leitura no Brasil e em diversos países em desenvolvimento é um fator preocupante. Estudos apontam que muitos leitores deixam de consumir livros devido à dificuldade em encontrar obras alinhadas aos seus interesses. Além disso, estudantes que se preparam para vestibulares e concursos enfrentam desafios para selecionar materiais adequados à sua jornada acadêmica. Um sistema de recomendação eficiente pode contribuir significativamente para incentivar a leitura e melhorar a qualidade da preparação educacional.

1.3 Justificativa

1.4 O desenvolvimento de um sistema de recomendação de livros fundamentado em Big Data e Machine Learning visa criar uma ferramenta capaz de fornecer sugestões personalizadas e de alta relevância para cada usuário. Diferente dos métodos tradicionais de curadoria, o uso de filtragem colaborativa, análise de conteúdo e redes neurais permite recomendações mais precisas, baseadas não apenas no histórico de leitura, mas também em avaliações de outros leitores e padrões de consumo.

1.4.1 Objetivo Geral:

O principal objetivo deste estudo é analisar como os sistemas de recomendação de livros podem ser aplicados no contexto educacional, auxiliando na personalização do aprendizado e no cumprimento do ODS 4, garantindo uma educação justa, abrangente e de qualidade para todos.

1.4.2 Objetivos Específicos:

- Investigar as abordagens principais utilizadas em plataformas de recomendação (como filtragem colaborativa, baseada em conteúdo e híbrida) e suas aplicações no contexto educacional.
- Analisar o impacto dos sistemas de recomendação na promoção da excelência educacional, com foco na recomendação de livros digitais, e como essa abordagem pode contribuir para reduzir as desigualdades no ensino.
- Avaliar a viabilidade da implementação de sistemas de recomendação personalizados para alunos com diferentes perfis e estágios de aprendizado, considerando variáveis como custo, acessibilidade e infraestrutura tecnológica.
- Propor alternativas para adaptar os sistemas de recomendação às especificidades do cenário educacional brasileiro, levando em consideração aspectos culturais, econômicos e sociais, com o objetivo de promover um ensino mais inclusivo e equitativo.

2 Referencial teórico compatível com o problema e objetivo do projeto

Os sistemas de recomendação (SR) são ferramentas computacionais que auxiliam na filtragem e seleção de itens relevantes para um usuário, com base em suas preferências e comportamentos (AGGARWAL, 2016). Esses sistemas são amplamente utilizados em plataformas de comércio eletrônico (como Amazon e Netflix), redes sociais e, mais recentemente, na educação (RICCI et al., 2015).

No contexto educacional, os SRs desempenham um papel crucial na personalização do aprendizado, sugerindo materiais didáticos, livros e atividades que se alinhem ao perfil e às necessidades individuais dos alunos (GÓMEZ-URIBE; HUNT, 2016). Essa abordagem está alinhada com o Objetivo de Desenvolvimento Sustentável (ODS) 4 da ONU, que visa garantir uma educação inclusiva, equitativa e de qualidade para todos.

3 Referências compatíveis com o tema estudado e citadas conforme normas ABNT

- AGGARWAL, Charu C. *Recommender Systems: The Textbook*. Springer, 2016. Este livro oferece uma introdução detalhada aos sistemas de recomendação, abordando desde os fundamentos e algoritmos clássicos até as técnicas mais avançadas aplicadas em diversos domínios, como comércio eletrônico, redes sociais e educação.
- GÓMEZ-URIBE, Carlos A.; HUNT, Neil. "The Netflix Recommender System: Algorithms, Business Value, and Innovation". *ACM Transactions on Management Information Systems*, 2016.

Este artigo examina o sistema de recomendação da Netflix, detalhando os algoritmos usados para personalizar o conteúdo para os usuários e como esses algoritmos agregam valor comercial à empresa.

- KAGGLE. Amazon Books Reviews Dataset. Disponível em: <https://www.kaggle.com/datasets/mohamedbakhmet/amazon-books-reviews>. Acesso em: 27 mar. 2025.
Este dataset contém resenhas de livros da Amazon, oferecendo uma fonte rica de dados para a análise de sentimentos, comportamento do consumidor e desenvolvimento de sistemas de recomendação de livros.
- MCKINSEY & COMPANY. "How Amazon's Recommendation Algorithm Drives 35% of Sales", 2018.
Este estudo analisa o impacto do algoritmo de recomendação da Amazon, destacando como ele contribui para 35% das vendas totais da empresa e a importância da personalização na experiência de compra.
- RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. Recommender Systems Handbook. Springer, 2015.
Este manual é uma referência abrangente sobre sistemas de recomendação, explorando diversas técnicas como filtragem colaborativa, análise de conteúdo e algoritmos híbridos, além de discutir desafios práticos e questões éticas relacionadas.

4. Metodologia

O estudo segue uma abordagem prática para construir e testar um sistema de recomendação utilizando a técnica de filtragem colaborativa. O trabalho está estruturado em duas fases principais: a criação e validação do modelo e a análise de seu desempenho com o uso de novas métricas de avaliação.

Primeiramente, os dados brutos foram importados e limpos, removendo valores nulos e selecionando apenas usuários que haviam avaliado pelo menos cinco livros. A análise focou nos 1.000 livros mais avaliados, garantindo que o conjunto de dados fosse adequado para o treinamento do modelo.

Os dados foram divididos em duas partes: 80% para treinamento e 20% para teste, assegurando uma avaliação precisa. A matriz de recomendação foi criada relacionando as avaliações dos usuários com os livros.

Para calcular a similaridade entre os livros, foi utilizado inicialmente o método do cosseno, e posteriormente aprimorado com a correlação de Pearson. O parâmetro de número de vizinhos (`n_neighbors`) foi ajustado para melhorar as previsões das avaliações.

A avaliação do modelo foi feita com duas métricas principais: o RMSE (Root Mean Squared Error), para medir a precisão das previsões, e a Acurácia, que foi calculada a partir da divisão das avaliações em duas categorias (considerando recomendação aquelas avaliações iguais ou superiores a 4).

A matriz de confusão foi gerada para visualizar os acertos e erros do modelo, e as métricas de Acurácia e RMSE foram usadas para quantificar a qualidade das previsões.

5. Resultados

Após a implementação e testes, os resultados obtidos foram:

RMSE (Raiz do Erro Quadrático Médio): 2.6123. Este valor indica que as previsões do modelo apresentam um erro dentro de um limite aceitável. Embora um RMSE menor seja desejável, o modelo apresenta um desempenho adequado.

- Acurácia: 75.32%. O modelo acertou 75% das previsões de recomendação, um desempenho positivo para este tipo de modelo.
- Abrangência da Recomendação: O modelo foi capaz de recomendar todos os livros do banco de dados, com uma abrangência de 100%.

- Matriz de Confusão: O modelo se mostrou eficiente em identificar tanto livros recomendados quanto os não recomendados, evidenciando uma boa precisão nos acertos.
- Sugestões Criadas: O modelo gerou 500 recomendações, evidenciando sua eficácia em fornecer sugestões consistentes.

6. Conclusão e Trabalhos Futuros

Conclusão: O modelo de recomendação baseado em filtragem colaborativa apresentou um desempenho satisfatório, com indicadores positivos como um RMSE de 2.6123 e uma acurácia de 75.32%. A abrangência de 100% nas recomendações e a consistência nas sugestões reforçam a utilidade do sistema em fornecer recomendações valiosas.

Próximos Passos:

Redução do RMSE: O sistema pode ser otimizado com ajustes nos parâmetros de vizinhos e testando outros métodos de similaridade, como a correlação de Spearman, além de combinar a filtragem colaborativa com outras técnicas.

Aumento da Precisão: A precisão das recomendações pode ser aprimorada com o uso de técnicas mais avançadas

[Link para o Repositório no Github](#)